

Laboratorio 6: Análisis de redes sociales en YouTube

Grupo #7

Marco Carbajal (23025) Carlos Angel (23010) Diego Monroy (23318)

Universidad del Valle de Guatemala — Facultad de Ingeniería

CC3084 Data Science — Sección 20 — Semestre II, 2026

6 de septiembre de 2026

1. Carga, comprensión e integración de los datos

1.1. Carga de los archivos

Se cargaron `youtube_videos.csv` (293 filas, 20 variables) y `youtube_comments.csv` (406 filas, 17 variables) con `pandas`. No hay filas ni llaves duplicadas en ninguno de los dos archivos.

1.2. Unidad de observación, llave primaria y variables relevantes

En `youtube_videos.csv` la unidad de observación es el **video** y la llave primaria es `video_id` (sin duplicados en 293 filas). Variables relevantes: `channel_id` (identificador estable del canal), `title` y `description` para análisis temático, `view_count` para popularidad, `category`, `source_query` y `source_group` para reconstruir el muestreo, y `publish_date` como única marca temporal absoluta.

En `youtube_comments.csv` la unidad de observación es el **comentario** y la llave primaria es `comment_id` (sin duplicados en 406 filas). Variables relevantes: `video_id` como llave foránea, `author_channel_id` para identificar al autor, `text` para el contenido, `like_count_text` y `reply_count` como medidas de recepción, y `channel_id`, que identifica al canal dueño del video comentado, no al autor.

1.3. Relación entre canal, video, autor, comentario, categoría y consulta

La estructura es jerárquica en dos niveles. Un canal (`channel_id`) publica varios videos: 97 canales para 293 videos, con mediana de 1 video por canal y máximo de 32. Cada video puede recibir varios comentarios y cada comentario tiene un autor (`author_channel_id`), un identificador de cuenta distinto del canal que publicó el video. La **categoría** es un atributo del video asignado por YouTube; se hereda al unir las tablas pero no describe al comentario ni al autor. La **consulta de búsqueda** es un atributo del procedimiento de recolección: `source_query` describe cómo se encontró el registro y `source_group` clasifica la estrategia. Ninguna describe el tema del video de forma confiable, por lo que se usan para auditar cobertura, no como variable temática. Además, autores de comentarios y canales de video son conjuntos **disjuntos**: ninguno de los 332 `author_channel_id` aparece como `channel_id` de un video.

1.4. Integración por `video_id`

Los **406 comentarios** (100 %) se asociaron con un video, así que no hay comentarios huérfanos. La relación es fuertemente asimétrica en el otro sentido: solo **19 de 293 videos** (6.5 %) y **8 de**

97 canales tienen comentarios recolectados. Las columnas redundantes coinciden al 100 % para `channel_id`, `channel_name` y el título, lo que confirma que la unión es consistente. La excepción es `source_group`, que coincide en apenas 53.7 % de los casos porque el mismo video fue alcanzado por una estrategia distinta en cada archivo.

2. Calidad, limpieza y preprocesamiento

2.1. Diagnóstico inicial de calidad

Tabla 1: Síntesis del diagnóstico de calidad.

Dimensión	Hallazgo
Dimensiones	videos 293×20 ; comentarios 406×17 .
Duplicados	0 filas y 0 llaves duplicadas en ambos archivos.
Faltantes (videos)	<code>published_time</code> y <code>view_count_text</code> : 13 (4.4 %); <code>description_snippet</code> : 25 (8.5 %); <code>description</code> : 26 (8.9 %).
Faltantes (comentarios)	0 nulos declarados, pero <code>like_count_text</code> guarda 189 cadenas en blanco (46.6 %) que el conteo de nulos no detecta.
Variables constantes	<code>is_pinned</code> (False) y <code>viewer_rating</code> (vacía) en comentarios; se descartan.
Consistencia IDs/nombres/handles	relación uno a uno para canales y autores; <code>video_id</code> de 11 caracteres, IDs de canal con patrón UC+22, handles con prefijo /@. <code>owner_handle</code> $\equiv$ <code>channel_handle</code> y <code>upload_date</code> $\equiv$ <code>publish_date</code> .
Atípicos	<code>view_count</code> muy asimétrica: mediana 1 175, límite intercuartílico 18 340, 49 videos por encima, encabezados por un video de Luisito Comunica con 8.19 millones. No son errores; se conservan y se usa escala logarítmica.

Hallazgo relevante para la interpretación: 36 de las 406 filas (8.9 %) tienen un `comment_id` con sufijo de respuesta y su comentario padre está en el mismo archivo, de modo que la afirmación de que “cada fila es un comentario principal” no se cumple del todo. Además, la suma de `reply_count` es 51 mientras que solo hay 36 respuestas presentes: la cobertura de segundo nivel es incompleta.

2.2. Variables que no pueden usarse o requieren precaución

Variable	Archivo	Decisión	Razón
<code>viewer_rating</code>	comentarios	descartar	vacía en las 406 filas
<code>is_pinned</code>	comentarios	descartar	constante False
<code>owner_handle</code>	videos	descartar	copia exacta de <code>channel_handle</code>
<code>upload_date</code>	videos	descartar	copia exacta de <code>publish_date</code>
<code>video_title</code>	comentarios	descartar	redundante con la unión por <code>video_id</code>
<code>published_time</code>	videos	precaución	fecha relativa al momento de recolección

Variable	Archivo	Decisión	Razón
<code>published_text</code>	comentarios	precaución	fecha relativa; no permite ordenar con exactitud
<code>view_count_text</code>	videos	precaución	texto con separador de miles y 13 faltantes
<code>like_count_text</code>	comentarios	precaución	189 blancos que se interpretan como cero
<code>reply_count</code>	comentarios	precaución	no identifica autores; no genera aristas
<code>channel_name</code>	ambos	precaución	etiqueta visible, no identificador
<code>source_query</code>	ambos	precaución	describe el muestreo, no el tema
<code>source_group</code>	ambos	precaución	difiere entre tablas para el mismo video
<code>keywords</code>	videos	precaución	lista vacía en 162 de 293 videos

`reply_count` es la variable más delicada: el enunciado advierte que no identifica a los autores de las respuestas y que no debe leerse como arista entre usuarios. Se usa únicamente como atributo de recepción del comentario.

2.3. Normalización de identificadores y nombres

Se garantizó que las llaves (`video_id`, `channel_id`, `comment_id`, `author_channel_id`) sean cadenas sin espacios y se mantengan como identificadores en todas las tablas derivadas. Los nombres visibles y los handles se conservan en columnas separadas, solo como etiquetas para las visualizaciones. Como la relación identificador–nombre–handle es uno a uno, no hay ambigüedad que resolver; los recortes y la verificación de formato se aplican de todos modos para que el procedimiento sea reproducible.

2.4. Conversión de variables de conteo almacenadas como texto

`like_count_text` no contiene abreviaturas ni separadores de miles: valores enteros simples o cadenas en blanco. Las **189 cadenas en blanco se imputan a cero** porque YouTube omite el contador cuando un comentario no tiene reacciones y el cero no aparece explícito en ninguna fila. Es una decisión de interpretación, no un dato observado, y afecta al 46.6 % de los comentarios. `view_count_text` sí trae separador de miles y el sufijo “vistas”; se parseó solo para auditoría: coincide con `view_count` en 227 de 280 registros con dato y en el resto la diferencia mediana es 0.05 %. Para todos los cálculos se usa `view_count`.

2.5. Versiones del texto

Se conservan dos columnas. `texto_original` es una copia sin modificar de `text` y sirve para auditoría y para el análisis de sentimiento, porque este depende de negaciones, mayúsculas sostenidas, signos de exclamación y emojis que la limpieza elimina. `texto_limpio` es la versión normalizada y lematizada que se usa para frecuencias de palabras y bigramas.

2.6. Decisiones de limpieza aplicadas a `texto_limpio`

- **Minúsculas:** para unificar “Guatemala”/“guatemala”; se pierde el énfasis por mayúsculas sostenidas, razón adicional para conservar el texto original.

- **URL:** se eliminan (no aportan vocabulario); solo 1 comentario tiene enlace.
- **Hashtags y menciones:** se separa el símbolo y se conserva la palabra; solo hay 1 hashtag y 5 menciones en todo el corpus, guardados además en columnas propias.
- **Puntuación y números:** se eliminan; los números son montos y años demasiado heterogéneos para tratarlos como categoría.
- **Stopwords:** lista en español de NLTK (313 términos) y descarte de tokens de ≤ 2 caracteres.
- **Lematización:** spaCy `es_core_news_sm` con los componentes de parseo y entidades desactivados. Introduce algo de ruido en palabras sin tilde, pero el saldo favorece el conteo de frecuencias.
- **Emojis:** se eliminan de `texto_limpio` pero se cuentan antes: 61 comentarios contienen al menos uno, 199 en total, y 5 comentarios son solo emojis.

2.7. Efecto cuantificado de la limpieza

Tabla 3: Efecto de la limpieza sobre los 406 comentarios.

Métrica	Valor
Registros eliminados	0
Textos modificados	396 de 406
Tokens antes / después	9 769 / 5 103 (−47,8 %)
Vocabulario antes / después	3 171 / 2 019
Textos vacíos antes / después	0 / 5
Duplicados exactos antes / después	2 / 6

No se elimina ningún registro. Cinco comentarios quedan vacíos porque eran solo emojis o una palabra corta (“que?”); se conservan porque siguen contando como participación válida para la red, pero quedan fuera del análisis de frecuencias. Los duplicados pasan de 2 a 6: los 2 originales son casos reales (mismo autor, mismo texto, mismo video, `comment_id` distinto) y los 4 adicionales aparecen porque la normalización colapsa variantes como “Excelente.”/“EXCELENTE”. Ninguno se elimina.

3. Análisis exploratorio

3.1. Descripción de los elementos mínimos

Tabla 4: Conteos generales.

Elemento	Valor	Elemento	Valor
Videos (catálogo)	293	Videos con ≥ 1 comentario	19
Canales (catálogo)	97	Canales con ≥ 1 comentario	8
Comentarios	406	Categorías de video	11
Autores únicos	332	Consultas (videos / comentarios)	21 / 6

Videos por canal: media 3.02, mediana 1, máximo 32; 65 de 97 canales (67 %) aportan un solo video. Los canales más presentes en el catálogo son Gobierno de la República (32), Municipalidad de Guatemala (27), Quorum (18) y PrensaLibre (17).

Comentarios y autores por video (Tabla 5): la razón autores/comentarios va de 0.71 a 1.0, es decir que casi todos los comentarios provienen de personas distintas.

Tabla 5: Videos con comentarios recolectados, ordenados por número de comentarios.

Video	Canal	Coment.	Autores	Likes	Resp.	Vistas
Qué rico come tu diputado	Quorum	161	128	358	–	11 775
La cooptación de W. Mazariegos en la USAC	Quorum	50	49	91	–	10 156
Inician trabajos del Puente Belice II	Gobierno	45	32	90	–	11 670
Plan 2032 Ciudad de Guatemala	Municipalidad	25	25	1 697	–	304 089
Conferencia de Prensa del Gobierno	Gobierno	25	19	20	–	3 628
EE.UU. envía a mexicanos deportados	N. Telemundo	25	18	25	–	14 200
Arroz con pollo a la MONOPOLIO	Quorum	16	16	–	–	1 954
Capturan a presuntos delincuentes...	Noti7	14	13	–	–	–
Internet: escoger el menos malo	Quorum	12	10	–	–	717
<i>otros 10 videos</i>		≤ 7	≤ 7			

Visualizaciones (293 videos): mediana 1 175, media 60 430, máximo 8.19 M. **Me gusta por comentario:** mediana 1, media 5.73, 189 comentarios con 0. **Respuestas:** 30 comentarios con `reply_count` > 0, suma 51, máximo 7.

Categorías: News & Politics domina con 138 videos y 335 comentarios. People & Blogs tiene 66 videos y **cero** comentarios recolectados, lo que confirma que la cobertura depende del muestreo y no del tema.

Consultas: 21 distintas para videos frente a 6 para comentarios; @quorumgt/videos sola aporta 231 de 406 comentarios. Por estrategia de recolección: `topic` 363 comentarios (12 videos), `channel` 43 (7 videos), `official_gov` 0 (105 videos).

Hashtags y menciones: 1 y 5 respectivamente en todo el corpus. **Vocabulario limpio:** 2019 términos sobre 5 103 tokens. Palabras más frecuentes tras la lematización: verbos auxiliares y luego *pueblo, guatemala, diputado, pagar, dinero*. Bigramas: *presidente bernardo, bernardo arevalo, pacto corrupto, diputado ser* — eje político claro (Figura 4).

3.2. Concentración de la participación

Un solo video, “Qué rico come tu diputado”, reúne el **39.7 %** de los comentarios; los tres primeros acumulan 63.1 % y los cinco primeros 75.4 %. El índice de Gini sobre los 19 videos comentados es **0.66**, y sube a **0.978** sobre los 293 videos del catálogo (274 con cero comentarios). A nivel de canal, Quorum aporta 256 comentarios (63.1 %) y los tres canales principales suman 86.5 %. Del lado de los autores el patrón se invierte: **286 de 332 (86.1 %)** escribieron un único comentario y solo 9 participaron en más de un video. Esa combinación anticipa la forma de estrella de la red bipartita (Figura 1).

3.3. Popularidad frente a participación

Entre los 19 videos comentados la asociación es fuerte y positiva: Spearman **0.811** ($p < 0,001$, $n = 19$) y correlación 0.718 entre los logaritmos. No es proporcional: la tasa de comentarios por

mil vistas varía en más de dos órdenes de magnitud, desde 19.2 (video con 52 vistas) hasta 0.08 en “Plan 2032 Ciudad de Guatemala” (304 089 vistas, 25 comentarios). Además, la mediana de vistas de los videos comentados (1 954) es apenas superior a la de los no comentados (1 150): la selección de videos para recolectar comentarios no siguió el criterio de popularidad. **Limitaciones de ambos conteos:** `view_count` es un acumulado desde la publicación, mientras que el número de comentarios recolectados es un tope impuesto por el *scraping*, no el número real de comentarios del video.

3.4. Visualizaciones




Figura 1: Videos con más comentarios (izq.) y curva de concentración acumulada (der.): el 80 % de los comentarios se alcanza en el sexto de diecinueve videos.




Figura 2: Distribución de la actividad por autor (izq.): decae de 286 autores con un comentario a 2 con seis. Comentarios por canal (der.): dominio de Quorum.




Figura 3: Categorías, catálogo frente a comentarios (izq.): People & Blogs, Education y Travel & Events tienen videos pero ninguna participación recolectada. Popularidad frente a participación en escala log-log (der.): “Plan 2032” queda claramente por debajo de la tendencia.




Figura 4: Palabras (izq.) y bigramas (der.) más frecuentes en el texto limpio.

3.5. Preguntas obligatorias (inciso 3.5)

¿Qué videos y canales concentran la mayor participación? “Qué rico come tu diputado” con 161 comentarios (39.7 %) y, a nivel de canal, Quorum con 256 (63.1 %). Le siguen Gobierno de la República (70) y un grupo de medios con 25 o menos.

¿Existen audiencias compartidas? Sí, pero muy poco. Solo 9 de 332 autores comentaron en más de un video y el solapamiento entre videos alcanza como máximo 2 autores compartidos (entre “Internet: escoger el menos malo” y “Arroz con pollo a la MONOPOLIO”, y entre “La cooptación...” y “Qué rico come tu diputado”). Solo 11 de los 171 pares posibles de videos comparten al menos un autor.

¿Qué autores funcionan como puentes? Los nueve autores multivideo, y en particular los que cruzan canales distintos: @virgiliogarcia3039 (Gobierno↔Quorum), @MarcosCarillo-b1r (Quorum↔TN23), @franciscoflores3120 (Gobierno↔Noti7), @moisesvaldez4043 (PrensaLibre↔Quorum). Sin ellos, cada canal quedaría como un grupo separado. Los dos autores con más videos son @inge_vergueta y @hashojea7348, ambos con 3 videos y solo dentro de Quorum.

¿Qué temas y sentimientos caracterizan a los grupos? Usando los videos como agrupamiento provisional y una polaridad por léxico, el corpus se divide en dos bloques. El **bloque crítico** (Quorum): vocabulario de *diputado*, *pueblo*, *sueldo*, *dinero*, *pacto corrupto* y la mayor proporción

de comentarios negativos (24 % en “Qué rico come tu diputado”, 20 % en el video de la USAC). El **bloque institucional** (Municipalidad y Gobierno): vocabulario de *proyecto*, *ciudad*, *presidente*, *saludos* y polaridad mayoritariamente positiva (64 % de positivos y ningún negativo en “Plan 2032”). El análisis formal está en la Sección 9.

¿La visibilidad coincide con la participación? Solo en parte. La correlación de rangos vistas–comentarios es alta (0.811), pero la tasa de comentarios por mil vistas varía en dos órdenes de magnitud y el video más visto del subconjunto es el que menos comenta en términos relativos. La visibilidad no explica qué videos entraron a la muestra.

¿Qué conclusiones quedan limitadas por la recolección? Prácticamente todas las que involucren el catálogo completo. El 93.5 % de los videos no tiene comentarios recolectados, los 105 videos del grupo `official_gov` tienen cero, y una sola consulta aporta más de la mitad de los comentarios. Cualquier afirmación sobre “qué temas generan más conversación en YouTube Guatemala” estaría midiendo la estrategia de *scraping*.

3.6. Preguntas adicionales (inciso 3.6)

1. **¿Los videos con más comentarios reciben más “me gusta”?** No necesariamente. La correlación de rangos es alta (0.871), pero “Plan 2032” concentra el 73 % de todos los “me gusta” con apenas el 6.2 % de los comentarios, mientras que el video más comentado reúne el 39.7 % de los comentarios y solo el 15.4 % de los “me gusta”. Comentar exige redactar; reaccionar no, y en este corpus se activan en videos distintos.
2. **¿La cobertura de comentarios depende de la estrategia de recolección?** De forma determinante. Los 105 videos de `official_gov` no tienen ni un comentario recolectado pese a una mediana de vistas comparable (521). `topic` aporta 363 comentarios y `channel` 43. La ausencia de comentarios en más del 90 % del catálogo es un artefacto del diseño.
3. **¿La extensión del comentario varía por canal?** Sí. Quorum promedia 26.4 palabras y Gobierno de la República 25.7, mientras Noti7 promedia 9.6 y TN23 solo 7.0. Los videos de análisis político generan intervenciones más largas; las notas de nota roja generan reacciones breves. Debe leerse con cuidado: los canales pequeños tienen muestras de 7 a 14 casos.

4. Construcción de la red bipartita autor–video

4.1. Construcción y definición de aristas y pesos

Se construyó un grafo **no dirigido** con dos conjuntos disjuntos de nodos: 332 autores (`author_channel_id`) y 19 videos comentados (`video_id`). Se crea una arista autor–video cuando ese autor publicó al menos un comentario en ese video, y el **peso** es el número de comentarios que ese autor publicó en ese video. Las 36 filas que son respuestas se cuentan como participación normal del autor en el video: la arista describe presencia, no jerarquía conversacional. Verificación: la suma de pesos es 406 = total de comentarios; el grafo es bipartito.

4.2. Tabla de nodos y tabla de aristas

Se entregan `nodos_bipartita.csv` (351 filas $\times$ 15 columnas) y `aristas_bipartita.csv` (343 filas $\times$ 6 columnas).

Tabla 6: Esquema de las tablas entregadas.

Tabla	Columnas
Nodos	id, etiqueta, tipo (autor/video), grado, grado_ponderado, comentarios, autores, videos, canales, likes, respuestas, author_handle (autores), channel_name, view_count, category (videos).
Aristas	origen (autor), destino (video), peso (núm. de comentarios), likes, respuestas, tipo_arista (autor-video).

Distribución de pesos de las 343 aristas: 303 con peso 1, 28 con 2, 7 con 3, 1 con 4, 2 con 5 y 2 con 6. Nodos de mayor grado ponderado: los videos “Qué rico come tu diputado” (128), “La cooptación...” (49) e “Inician trabajos del Puente Belice II” (32); del lado autor, @hashojea7348 e @inge_vergueta con grado ponderado 4 y 3.

4.3. Visualización de la red completa




Figura 5: Red bipartita autor-video: 351 nodos (332 autores en azul, 19 videos en rojo) y 343 aristas. Cada video es el centro de una estrella de autores que solo aparecen ahí; las estrellas se unen débilmente por los pocos autores puente.




Figura 6: Distribución de grados. Lado autores (izq.): 323 de 332 tienen grado 1. Lado videos (der.): grado muy dispar, con un video que concentra 128 autores distintos.

Densidad bipartita 0.054. Grado medio de autores **1.03** (máximo 3), de videos **18.05** (máximo 128). La red se separa en **10 componentes conexas**: la mayor tiene **286 nodos (81.5 %)** y agrupa 10 videos unidos exclusivamente por los autores multivideo; las otras nueve son videos aislados con su propio público. **Eliminar menos de diez autores puente fragmentaría la componente mayor por video.**

4.4. Qué significa una arista

Una arista autor–video significa una sola cosa: ese autor publicó al menos un comentario en ese video, y el peso indica cuántos. **No** implica que el autor haya visto el video completo ni que apruebe su contenido (buena parte de los comentarios son críticos). Dos autores conectados al mismo video no son amigos, no se conocen y no necesariamente se leyeron: comparten un espacio de publicación, no una conversación. La ausencia de arista tampoco es desinterés: 274 videos del catálogo no tienen aristas porque no se recolectaron sus comentarios. La red describe *participación observada*, no participación real.

5. Proyecciones de la red

5.1. Construcción de las proyecciones

Autor–autor: dos autores se conectan si comentaron en el mismo video; el peso es el número de videos compartidos. Resultado: 332 nodos y **10 732** aristas (10 730 con peso 1, solo 2 con peso 2). **Video–video:** dos videos se conectan si comparten al menos un autor; el peso es el número de autores compartidos. Resultado: 19 nodos y **11** aristas (9 con peso 1, 2 con peso 2).

5.2. Comparación de las proyecciones

Tabla 7: Comparación de las dos proyecciones.

Métrica	Autor–autor	Video–video
Nodos	332	19
Aristas	10 732	11
Densidad	0.195	0.064
Grado medio	64.65	1.16
Componentes	10	10
Nodos aislados	4	9

La proyección **autor–autor** representa *coaudiencia*: casi todas sus aristas nacen de autores que comentaron en el mismo video, de modo que cada video genera un *clique* completo de sus comentaristas. Por eso tiene decenas de miles de aristas y una transitividad casi perfecta, pero esa densidad es un artefacto de la proyección, no evidencia de interacción real. La proyección **video–video** representa *solapamiento de público*: mide cuántos videos comparten comentaristas. Es dispersa (solo 11 aristas) porque el solapamiento de audiencias entre videos es mínimo. Cada proyección responde a una pregunta distinta: la primera, “¿qué autores coincidieron?”; la segunda, “¿qué contenidos comparten audiencia?”.

5.3. Visualización de las proyecciones




Figura 7: Proyección video–video (grosor de arista = autores compartidos). Solo 10 de 19 videos tienen alguna conexión; 9 quedan aislados.




Figura 8: Proyección autor-autor coloreada por componente conexo (332 nodos, 10 732 aristas). Cada cúmulo denso corresponde a los comentaristas de un mismo video.

6. Topología y fragmentación

6.1. Nodos, aristas, densidad, grado y componentes

Tabla 8: Resumen topológico de las tres redes.

Red	Nodos	Aristas	Dens.	$\bar{k}$	$k_{\max}$	Comp.	Comp. mayor	% mayor
Bipartita autor-video	351	343	0.054	1.95	128	10	286	81.5
Proyección autor-autor	332	10 732	0.195	64.65	183	10	276	83.1
Proyección video-video	19	11	0.064	1.16	4	10	10	52.6




Figura 9: Distribución de grados en las proyecciones. Autor–autor (izq.): grados altos por el efecto *clique*. Video–video (der.): grados ≤ 4 , muchos videos con grado 0.

La distribución de grados está fuertemente sesgada en la bipartita: la mayoría de los nodos (los autores) tiene pocas conexiones y el grado está concentrado en unos pocos videos.

6.2. Cohesión y transitividad

Tabla 9: Cohesión y transitividad.

Red	Transit. global	Clustering medio	Diámetro (comp. mayor)	Dist. media
Bipartita autor–video	0.000	0.000	12	4.715
Proyección autor–autor	0.984	0.972	6	2.356
Proyección video–video	0.316	0.149	5	2.489

La transitividad de la bipartita es **0 por construcción** (no hay triángulos en un grafo bipartito). En la proyección autor–autor es casi 1 por el efecto *clique*, no por cohesión social genuina. En la proyección video–video, 0.316 indica que cuando dos videos comparten público con un tercero, a veces (pero no siempre) también lo comparten entre sí.

6.3. Nodos, videos y grupos periféricos o aislados

Aislamiento observado (dentro de la red): 323 de 332 autores (97.3 %) tienen grado 1 en la bipartita; 4 autores quedan aislados en la proyección autor–autor (comentaron en videos sin ningún coautor); 9 de 19 videos quedan aislados en la proyección video–video. **Ausencia de datos (fuera de la red):** 274 de 293 videos del catálogo (93.5 %) no aparecen como nodos porque no se recolectaron sus comentarios, **no** porque se haya observado que carecen de audiencia. La distinción es esencial: el primer grupo es un resultado, el segundo es una limitación de cobertura.

6.4. Interpretación de los hallazgos estructurales

La topología confirma y precisa lo visto en el análisis exploratorio:

- **Estructura de estrellas.** El grado medio de autores (1.03) frente al de videos (18.05) y la transitividad nula de la bipartita describen un grafo donde cada video es un centro y los autores son hojas. No hay comunidades de discusión: hay audiencias yuxtapuestas.

- **Fragmentación alta y cohesión frágil.** Diez componentes; la mayor cubre el 81.5 % pero su conectividad depende de < 10 autores puente. El diámetro 12 y la distancia media 4.7 en la bipartita indican que incluso dentro de la componente mayor los videos están “lejos” entre sí: para ir de un video a otro hay que pasar por un autor puente y otro video.
- **Las proyecciones engañan si se leen sin contexto.** La autor–autor parece una red social densa (densidad 0.195, clustering 0.97) pero esa densidad es mecánica. La video–video, que sí mide un fenómeno real (solapamiento de público), es casi vacía: las audiencias de estos videos apenas se tocan.
- **El aislamiento observado es real; la ausencia de datos, no.** Se puede afirmar que estos 332 autores rara vez comentan en más de un video; no se puede afirmar nada sobre los 274 videos sin datos.

7. Comunidades

7.1. Selección de la red y justificación

Se detectan comunidades sobre la **red bipartita autor–video ponderada**, no sobre las proyecciones. Razones: (i) la proyección autor–autor está formada por *cliques* de video, de modo que cualquier algoritmo recuperaría trivialmente “un grupo por video” y la modularidad resultante sería un artefacto; (ii) la proyección video–video tiene solo 11 aristas y 9 nodos aislados, insuficiente para una partición informativa; (iii) la bipartita conserva toda la información (quién comenta dónde y cuántas veces) y permite que los autores puente unan comunidades en lugar de forzar una por video. Louvain admite grafos bipartitos ponderados aunque no fue diseñado específicamente para ellos; se acepta esta limitación y se interpreta el resultado en consecuencia.

7.2. Algoritmo aplicado

Se aplicó **Louvain** (`networkx.algorithms.community.louvain_communities`) con `weight='weight'`, `resolution=1.0` y `seed=7` para reproducibilidad. Louvain optimiza la **modularidad** de forma voraz y jerárquica. Supuestos: las comunidades son disjuntas (cada nodo pertenece a una sola) y densamente conectadas hacia dentro respecto a un modelo nulo de configuración. **Tratamiento de los pesos:** el peso (número de comentarios de un autor en un video) entra directamente en la modularidad, de modo que un autor que comenta muchas veces en un video queda más firmemente ligado a su comunidad.

7.3. Número de comunidades, tamaños y calidad

Tabla 10: Comunidades detectadas con Louvain.

Número de comunidades	17
Modularidad	0.777
Tamaños	126, 48, 32, 31, 26, 19, 19, 14, 8, 8, 5, 4, 3, 2, 2, 2, 2

La modularidad 0.777 es alta, lo que confirma que la red se separa muy bien en bloques. Esto era esperable dada la estructura de estrellas: casi cada comunidad coincide con el público de un video.

Comunidades detectadas con Louvain (17 comunidades, modularidad 0.777)




Figura 10: Comunidades detectadas con Louvain (17 comunidades, modularidad 0.777). Los cuadrados son videos, los círculos autores; el color indica la comunidad.

7.4. Caracterización de las tres comunidades principales

Tabla 11: Las tres comunidades más grandes.

Com.	Videos (canal)	Aut.	Coment.	Temas frecuentes		Sentimiento
1	“Qué rico come tu diputado” (Quorum)	125	161	pueblo, pagar	diputado,	65 % neutral, 24 % negativo, 11 % positivo
2	“La cooptación de W. Mazariegos en la USAC” (Quorum)	47	50	corrupto, universidad	universi-	64 % neutral, 20 % negativo, 16 % positivo
3	3 videos de Quorum (movilidad, internet, mercado)	29	~34	excelente, ciudad, internet		47 % neutral, 47 % positivo, 6 % negativo

La **Comunidad 1** es, por sí sola, casi tan grande como el resto: reúne 161 comentarios, sentimiento mayoritariamente neutral con un 24 % de negativos (por encima del 15.5 % general). La **Comunidad 2** gira en torno a “corrupto” y la universidad, con perfil de sentimiento similar.

La **Comunidad 3** es la única que fusiona más de un video, producto de los autores puente; su sentimiento es mucho más equilibrado y aparece “excelente” entre las palabras frecuentes, lo que sugiere una audiencia distinta, más afín al canal, que comenta varios videos con tono elogioso en lugar de crítico.

8. Nodos centrales y participantes puente

8.1. Medidas de centralidad y su justificación

Se calcularon tres medidas complementarias sobre la red bipartita:

- **Intermediación (betweenness)**, no ponderada y normalizada: mide cuántos caminos más cortos pasan por un nodo. Es la medida clave para identificar *puentes*: en una red fragmentada como esta, los nodos con betweenness alto son los que mantienen conectada la componente mayor.
- **PageRank** ponderado por el peso de las aristas: mide importancia recursiva y absorbe bien la asimetría de grado; identifica los videos y autores que reciben “más flujo” de participación.
- **Centralidad de vector propio**, calculada solo sobre la componente mayor (no está definida en un grafo desconectado): mide estar conectado a nodos que a su vez están bien conectados.

No se reportó cercanía global porque la red está desconectada; el diámetro y la distancia media ya se reportaron en la Sección 6.2.

8.2. Interpretación separada para autores y videos

Videos — alcance y capacidad de conectar audiencias. PageRank e intermediación coinciden en el mismo orden: “Qué rico come tu diputado” (PageRank 0.167, betweenness 0.566), “La cooptación...” (0.063 / 0.227), “Inician trabajos del Puente Belice II” (0.043 / 0.188) y “Conferencia de Prensa del Gobierno” (0.025 / 0.244). Los dos primeros dominan por volumen de comentaristas; los dos siguientes tienen betweenness alto relativo a su tamaño porque están pegados a autores puente que conectan Quorum con Gobierno.

Autores — recurrencia y diversidad. Solo **9 de 332 autores** tienen betweenness > 0; son exactamente los autores multivideo. Los de mayor intermediación son @virgiliogarcia3039 (3 coment., 2 videos, betweenness 0.232), @inge_vergueta (3 coment., 3 videos, 0.218) y @josegil3813 (2 coment., 2 videos, 0.177). La recurrencia (comentar mucho) y la diversidad (comentar en varios videos) no coinciden: @hashojea7348 tiene 4 comentarios pero betweenness bajo (0.060) porque sus 3 videos son todos de Quorum y no conectan bloques distintos.

8.3. Participantes recurrentes, autores puente y videos articuladores

En la componente mayor (286 nodos) hay **17 puntos de articulación: 7 autores y los 10 videos**. Que los 10 videos sean puntos de articulación es la firma de la estructura de estrellas: quitar cualquier video desconecta a todos sus comentaristas exclusivos. Los 7 autores articuladores (@franciscoflores3120, @josegil3813, @virgiliogarcia3039, @moisesvaldez4043, @hashojea7348, @inge_vergueta, @MarcosCarillo-b1r) son los que, si se eliminan, parten la componente mayor en trozos por video. **La conectividad global de la red depende de siete personas.**

9. Análisis de contenido y sentimiento

9.1. Método de análisis de sentimiento y su justificación

Se clasificó cada comentario en **positivo**, **negativo** o **neutral** con un **léxico de polaridad en español adaptado al dominio**. El procedimiento normaliza el texto original (minúsculas y eliminación de tildes), cuenta ocurrencias de dos listas de palabras (una positiva: *excelente, gracias, felicidades, apoyo, esperanza, orgullo...*; una negativa: *corrupto, ladrón, mentira, pésimo, fraude, impunidad, vergüenza...*) y asigna la polaridad por mayoría; el empate se resuelve como **neutral**.

Justificación de la elección:

- **Tamaño del corpus.** Con 406 comentarios no hay datos para entrenar ni validar un clasificador supervisado; un método basado en léxico no requiere entrenamiento.
- **Dominio.** El corpus es de comentarios políticos guatemaltecos. Los léxicos y modelos genéricos (entrenados sobre reseñas de productos o tuits genéricos) subestiman señales locales como “pacto corrupto”, “impunidad” o “inepto”. Una lista curada a mano permite incorporar ese vocabulario.
- **Reproducibilidad e interpretabilidad.** El léxico corre sin GPU, es determinista y cada clasificación es auditable (se sabe exactamente qué palabra la produjo), lo que es deseable en un laboratorio.
- **Consistencia con la limpieza.** Se aplica sobre `texto_original`, conservando mayúsculas, signos y emojis que la versión lematizada elimina.

Limitaciones reconocidas del método: no maneja negación (“no es corrupto” se cuenta como negativo), ni intensidad, ni ironía; sobre-asigna la clase **neutral** cuando el comentario no contiene palabras del léxico (61.6 % de los casos); y las listas, al ser manuales, tienen cobertura incompleta. Un modelo transformer en español (por ejemplo BETO afinado, o `pysentimiento`) daría una clasificación más fina y es la extensión natural de este trabajo; los resultados que siguen deben leerse como una aproximación de primer orden.

9.2. Distribución general y comparación por video, canal y comunidad

Tabla 12: Distribución general de sentimiento (406 comentarios).

Polaridad	Comentarios	Proporción
Neutral	250	61.6 %
Positivo	93	22.9 %
Negativo	63	15.5 %

Tabla 13: Sentimiento por video (videos con ≥ 10 comentarios).

Video	n	Neg.	Neutral	Pos.
Qué rico come tu diputado	161	0.24	0.65	0.11
La cooptación de W. Mazariegos en la USAC	50	0.20	0.64	0.16
Inician trabajos del Puente Belice II	45	0.16	0.49	0.36
Conferencia de Prensa del Gobierno	25	0.04	0.68	0.28
EE.UU. envía a mexicanos deportados	25	0.08	0.72	0.20
Plan 2032 Ciudad de Guatemala	25	0.00	0.36	0.64
Arroz con pollo a la MONOPOLIO	16	0.06	0.56	0.38
Capturan a presuntos delincuentes. . .	14	0.00	0.86	0.14
Internet: escoger el menos malo	12	0.08	0.42	0.50

Tabla 14: Sentimiento por canal (canales con ≥ 10 comentarios).

Canal	n	Neg.	Neutral	Pos.
Quorum	256	0.20	0.62	0.17
Gobierno de la República de Guatemala	70	0.11	0.56	0.33
Municipalidad de Guatemala	25	0.00	0.36	0.64
Noticias Telemundo	25	0.08	0.72	0.20
Noti7	14	0.00	0.86	0.14

9.3. Hallazgos de contenido y sentimiento

- **El corpus es predominantemente neutral** (61.6 %), en parte real (muchos comentarios son preguntas, datos o etiquetados de terceros) y en parte un efecto del método, que marca neutral todo comentario sin palabras del léxico.
- **La polaridad depende del emisor, no del tema en abstracto.** Los videos de Quorum concentran la negatividad (20 % negativo, 24 % en el video de los diputados); los de la Municipalidad de Guatemala no tienen ni un comentario negativo y son 64 % positivos. Un mismo asunto — política y gestión pública — produce comentarios críticos cuando lo publica un medio de fiscalización y comentarios de felicitación cuando lo publica la institución aludida.
- **El vocabulario acompaña al sentimiento.** En las comunidades críticas dominan *diputado*, *pueblo*, *pagar*, *dinero*, *corrupto*; en las institucionales, *proyecto*, *ciudad*, *excelente*, *felicidades*. Los bigramas más frecuentes del corpus (*pacto corrupto*, *bernardo arevalo*, *diputado ser*) confirman que el eje temático es la política nacional.
- **Los “me gusta” refuerzan el contenido positivo institucional:** “Plan 2032” concentra el 73 % de los “me gusta” del corpus con un 64 % de comentarios positivos, mientras el video más comentado (crítico) recibe muchos comentarios pero pocas reacciones.
- **Cautela por tamaño de muestra:** la comparación por canal solo es sólida para Quorum ($n = 256$) y Gobierno ($n = 70$); los demás canales tienen 14–25 comentarios y sus porcentajes son orientativos.

10. Interpretación, limitaciones y conclusiones

10.1. Los hallazgos en el contexto de participación y consumo en YouTube

El retrato que emerge es coherente con lo que se sabe del consumo de contenido en plataformas de video: una minoría muy activa produce la mayor parte del texto y una mayoría silenciosa (o de una sola intervención) constituye el grueso de la audiencia. En estos datos, el 86 % de los autores comenta una única vez y tres videos concentran el 63 % de los comentarios. La participación por escrito se organiza alrededor de **piezas de contenido**, no de **comunidades de usuarios**: la gente llega a un video, comenta y no vuelve a cruzarse con los demás comentaristas en otro video. Esto explica por qué la red bipartita tiene forma de estrellas y por qué su cohesión depende de un puñado de usuarios recurrentes.

También se observa que **comentar y reaccionar son conductas distintas**: los videos que concentran comentarios (análisis político crítico) no son los que concentran “me gusta” (comunicación institucional positiva). Y el tono del comentario está fuertemente condicionado por quién publica el video: los medios de fiscalización atraen crítica, las instituciones atraen felicitaciones. La conversación observada es, en su mayor parte, política nacional guatemalteca (diputados, presidente Arévalo, pacto de corruptos, USAC).

10.2. Limitaciones

1. **Cobertura de comentarios.** Solo 19 de 293 videos (6.5 %) tienen comentarios recolectados y el número de comentarios por video parece topado por el *scraping* (máximo 161). No se conoce el volumen real de conversación de ningún video, ni si los comentarios recolectados son los primeros, los más votados o una muestra sesgada.
2. **Selección por consultas.** Una sola consulta (@quorumgt/videos) aporta 231 de 406 comentarios, y el grupo `official_gov` (105 videos) no aporta ninguno. El corpus refleja la estrategia de búsqueda del recolector, no la actividad de la plataforma.
3. **Fechas relativas.** `published_time` y `published_text` (“hace 2 días”, “hace 3 meses”) dependen del momento de recolección y no permiten ordenar eventos con precisión ni construir series temporales. La única fecha absoluta, `publish_date`, existe solo para videos.
4. **Conteos observados al momento de recolección.** `view_count` y `like_count` son fotografías de un instante; `view_count` es acumulado desde la publicación mientras que el conteo de comentarios es un tope de muestreo. Compararlos mezcla dos escalas temporales distintas.
5. **Falta de relaciones explícitas entre autores.** Los datos no permiten saber quién respondió a quién: `reply_count` no identifica autores y solo 36 de las 51 respuestas declaradas están presentes. Toda la estructura de red se basa en *coparticipación* (comentar en el mismo video), no en interacción directa.
6. **Concentración de comentarios en pocos videos.** El Gini sobre el catálogo completo es 0.978. Cualquier estadístico agregado está dominado por dos o tres videos de un solo canal (Quorum), de modo que “el comportamiento promedio” del corpus es en realidad el comportamiento de esos videos.

10.3. Descripción, asociación e inferencia

- **Descripción** (lo que los datos dicen directamente): hay 406 comentarios de 332 autores en 19 videos de 8 canales; el 39.7 % de los comentarios está en un video; el 15.5 % de los comentarios se clasificó como negativo; hay 7 autores cuya eliminación fragmenta la componente mayor.

- **Asociación** (relaciones observadas en *esta* muestra, sin causalidad): a mayor número de vistas, mayor número de comentarios entre los 19 videos ($\rho = 0,811$); los videos de Quorum se asocian con más comentarios negativos que los de la Municipalidad; los comentarios más largos se asocian con canales de análisis político.
- **Inferencia** (lo que *no* se puede concluir): no se puede afirmar que el video crítico “genere” negatividad, ni que los usuarios de YouTube en Guatemala se comporten así, ni que la población guatemalteca opine lo que opinan estos 332 autores. La muestra no es aleatoria ni representativa: es el resultado de un conjunto concreto de consultas sobre un conjunto concreto de canales. Los resultados describen este corpus y no se generalizan.

10.4. Conclusiones integradas

1. **Estructura.** La participación escrita observada se organiza como estrellas video-comentaristas débilmente unidas. La red bipartita tiene 351 nodos y 343 aristas, densidad 0.054, grado medio de autores 1.03 y transitividad 0. Se fragmenta en 10 componentes; la mayor (81.5 % de los nodos) se sostiene sobre menos de diez autores puente, de los cuales 7 son puntos de articulación.
2. **Comunidades.** Louvain encuentra 17 comunidades con modularidad 0.777, pero esa nitidez es consecuencia de la estructura de estrellas: cada comunidad es, esencialmente, el público de un video. La única comunidad que fusiona varios videos lo hace gracias a los autores puente y tiene un tono marcadamente más positivo que las demás.
3. **Centralidad.** Los nodos clave son pocos y claros: dos videos de Quorum concentran alcance y PageRank; siete autores recurrentes concentran toda la intermediación. La influencia en esta red no es difusa, es puntual.
4. **Contenido y sentimiento.** El corpus es política nacional y es mayoritariamente neutral (61.6 %), con un 15.5 % negativo y un 22.9 % positivo. La polaridad la determina el emisor del video: los medios de fiscalización atraen crítica (Quorum, 20 % negativo) y las instituciones atraen felicitaciones (Municipalidad, 64 % positivo, 0 % negativo).
5. **Limitaciones.** Todo lo anterior describe un subconjunto sesgado por el procedimiento de recolección: el 93.5 % del catálogo no aporta comentarios y una consulta aporta más de la mitad. Las conclusiones son válidas para este corpus y no se extienden a YouTube ni a Guatemala. La estructura de red se basa en coparticipación, no en interacción directa, y el análisis de sentimiento es una aproximación por léxico que conviene refinar con un modelo transformer en español en trabajo futuro.

Reproducibilidad

El análisis completo está en el notebook `Laboratorio6_DS_Grupo7.ipynb`. Dependencias en `requirements.txt` (`pandas`, `numpy`, `scipy`, `matplotlib`, `networkx`, `nltk`, `spacy` con `es_core_news_sm`, `emoji`). Ejecución: `uv venv && uv pip install -r requirements.txt` y correr el notebook de arriba abajo. Se generan `nodos_bipartita.csv` y `aristas_bipartita.csv`. Semillas fijas (`seed=7`) en `layouts` y en Louvain. Repositorio: https://github.com/marcocarbalb/lab6_DS